

Fruit Classification by Extracting Color Chromaticity, Shape and Texture Features: Towards an Application for Supermarkets

F. García, J. Cervantes, A. López and M. Alvarado

Abstract— In this paper we present an approach for fruit recognition using artificial vision, towards to employ it as an application for supermarkets. The fruit's visual features extracted are shape, texture and –we focus on– the extraction of the color chromaticity. From the few related works on fruit recognition, the color extraction is performed in the RGB (Red, Green, Blue) space. We claim as necessary to employ the chromaticity of colors to characterize the color of the fruits. Thus, we propose to use the HSV (Hue, Saturation, Value) space because it is possible to extract and process the chromaticity data, but without the undesirable intensity effects of the RGB space. On the other hand, before the color is characterized, we complete a selection of the chromaticities that contribute with important data about the fruits. Our approach's strength is validated by performing test on 20 common fruit classes: this proposal outperforms the color characterization of related work.

Keywords— Color characterization, color spaces, feature extraction.

I. INTRODUCCIÓN

ACTUALMENTE se está volviendo común que la gente haga sus compras en supermercados, debido a la comodidad que ofrecen estos lugares. Una de estas comodidades es al momento de pagar los productos, los cuales son registrados por sus códigos de barras. Esta situación es fácil para productos que están empaquetados; sin embargo, las frutas no siempre son empaquetadas porque hay personas que prefieren escoger por ellas mismas las frutas que contemplan comprar. Las frutas no tienen códigos de barras impresos que faciliten la clasificación automática; usualmente el cajero introduce diferentes códigos a la computadora para identificar la fruta.

Los cajeros pueden memorizar los códigos, pero es difícil recordar todos los códigos debido a la gran cantidad de frutas que pueden llegar a vender los supermercados. Por otra parte, el cajero puede obtener los códigos al consultar catálogos, en los cuales pueden tener imágenes de las frutas para facilitar el reconocimiento, pero esto puede ser tardado al tener que hojear dicho catálogo.

Muchos de los trabajos relacionados sobre reconocimiento de frutas que se revisaron se han concentrado en evaluar la calidad de las frutas [1]–[4], o de los productos que se obtienen

de ellos [5], [6], o para determinar la madurez o el momento adecuado para recolectar las frutas [7]–[10]. En la mayoría de los trabajos revisados no se reconocen diferentes clases de frutas [4], [11], estos se concentran en un solo tipo de fruta, por ejemplo, aceitunas [7], manzanas [12] o mangos [13], en los cuales se analizan características específicas para determinar la calidad o la madurez. Varios de ellos emplean visión artificial [14] para extraer las características de las frutas, pero otros trabajos emplean, además de visión artificial, diferentes sensores, por ejemplo, sensores espectroscópicos [4], [15], o narices y lenguas electrónicas [16]. Pero estos sensores pueden ser caros, difíciles de instalar y de mantener en los supermercados.

Por otra parte, los seres humanos pueden reconocer frutas empleando el sentido de la vista, sin emplear otro sentido. Es decir, los humanos son capaces de reconocer las frutas al olerlas y/o tocarlas; sin embargo es posible es posible reconocerlas con tan solo observarlas. De aquí que un sistema de visión artificial es adecuado para este propósito; es importante mencionar que actualmente los sistemas de visión son baratos, fáciles de instalar y de mantener.

Las características que los humanos necesitan extraer de las frutas para identificarlas son la forma, la textura y el color. En este trabajo proponemos caracterizar la forma de las frutas empleando los descriptores de Fourier [17] y los momentos de Hu [18]; ambos métodos han sido empleados ampliamente para modelar la forma de objetos de forma precisa. Algunas características geométricas básicas también son extraídas y agregadas para caracterizar la forma. La textura es modelada con las características extraídas de las matrices de co-ocurrencia de niveles de gris [19].

La caracterización del color es la contribución de este artículo. En los trabajos relacionados que se revisaron el color es representado empleando el espacio RGB; el inconveniente con este espacio de color es que los colores con la misma cromaticidad pueden ser clasificados como colores diferentes si sus intensidades no son iguales. Por ejemplo, la cromaticidad de los tomates mostrados en la Fig. 1 es roja, pero la intensidad del tomate (a) es ligeramente mayor que la intensidad del tomate (b); dado esto, en el espacio RGB, los colores de ambos tomates son reconocidos como diferentes.

Esto es un problema para nuestro propósito, porque, usualmente, la intensidad del color de las frutas de la misma clase puede variar dependiendo de la madurez de la fruta, como se muestra en la Fig. 1; a pesar de que las condiciones de la iluminación dentro de los supermercados pueden ser controladas.

Los humanos pueden reconocer los colores por la

F. García, Universidad Autónoma del Estado de México, Texcoco, Estado de México, México, fgarcial@uaemex.mx

J. Cervantes, Universidad Autónoma del Estado de México, Texcoco, Estado de México, México, chazarra17@gmail.com

A. López, Universidad Autónoma del Estado de México, Zumpango, Estado de México, México, alchau@uaemex.mx

M. Alvarado, Centro de Investigación y de Estudios Avanzados del IPN, México DF, México, matias@cs.cinvestav.mx




Figura 1. Tomates con la misma cromaticidad y con diferentes intensidades, la intensidad del color del tomate (a) es mayor que la del tomate (b).

cromaticidad, independientemente de la intensidad. La intensidad es una característica importante para los trabajos que analizan y estudian la madurez de las frutas; pero, para este estudio, la intensidad del color de las frutas no es relevante. La extracción de la cromaticidad de los colores en el espacio RGB no siempre es precisa porque la información de la cromaticidad puede ser afectada por la intensidad. De aquí que empleamos el espacio HSV para representar los colores porque en este espacio la cromaticidad está desacoplada de la intensidad [20]; pero también porque la representación de colores en este espacio emula la percepción humana del color [21]. Empleando el espacio HSV, la diferencia de intensidades de los tomates mostrados en la Fig. 1 no afecta el reconocimiento del color de ambos tomates.

Los trabajos encontrados que abordan el reconocimiento de frutas, empleando visión artificial, son presentados en [22], [23] y [24]. En [23] y [24] se caracteriza el color al calcular el promedio de cada canal de color. La desventaja con este enfoque es que, como mencionamos anteriormente, dependen de la intensidad del color. Zhang et al. [22] discretizan los canales de color en 4 niveles de intensidad, después calculan un histograma donde se registran las frecuencias de los 64 colores posibles. La propuesta de [22] es novedosa y pareciera que la intensidad no afecta la cromaticidad; sin embargo, el hecho de que los colores sean representados y procesados en el espacio RGB, nos lleva a considerar que también es susceptible de sufrir el mismo efecto.

Por otra parte, nuestra propuesta consiste en caracterizar el color por su cromaticidad, ya que como se menciona anteriormente, con la información de la cromaticidad es suficiente para que los humanos puedan identificar el color, en este caso, el color característico de las frutas. Pero antes de que el color sea extraído con nuestro método, proponemos seleccionar los colores discriminativos de las frutas. Esto es, no siempre el color de la superficie de la fruta es homogéneo, esta puede tener áreas pequeñas con colores que no aportan información importante sobre el color característico de la fruta; lo que puede ocasionar que el reconocimiento del color sea impreciso. De aquí que los colores que no aportan información relevante son eliminados; esto se logra al eliminar los colores con alta varianza respecto a la distribución de los colores porque no representan información característica sobre la fruta.

El artículo se divide como sigue: en la sección II se presentan trabajos relacionados; en la sección III mostramos nuestra propuesta de extracción de características. En la sección IV presentamos los resultados obtenidos al procesar imágenes de 20 clases de frutas; se discute el desempeño de nuestra propuesta en la sección V. El artículo termina con conclusiones y trabajo futuro en la sección VI.

II. TRABAJOS PREVIOS

Como se ha mencionado anteriormente, existen pocos trabajos que aborden el reconocimiento de frutas empleando visión artificial. La mayoría de los trabajos se concentran en reconocer subclases de una misma clase de fruta o en determinar la madurez de una clase específica de fruta. A continuación se presentan los trabajos relacionados al reconocimiento de frutas, encontrados en el estado del arte.

En [1] se emplea un sistema de visión artificial para medir la heterogeneidad del color de las frutas; graficando la dispersión de los valores a^*b^* pertenecientes a los píxeles de la imagen se obtiene información sobre la forma de los cúmulos de puntos. Las características geométricas describen la forma de los cúmulos de forma cuantitativa; con esta información es posible estudiar las propiedades químicas de determinadas frutas.

Manickavasagan et al. [3] determinan la eficiencia de una técnica de procesamiento de color en RGB de imágenes para clasificar dátiles. Se extraen características de forma y de textura, estas últimas se obtienen calculando las matrices de co-ocurrencia de niveles de gris. En total se extraen 13 características por cada canal de color.

Un sistema de visión artificial para determinar el contenido de las impurezas de muestras de aceite de oliva virgen es presentado en [5]. El color de las muestras son modeladas al construir histogramas de los canales de color de los espacios RGB, CIELAB y HSV.

Gatica et al. [7] presentan un método para reconocer y estudiar aceitunas con imágenes RGB adquiridas de árboles de olivo, con el fin de determinar el momento adecuado para cosechar sus frutos.

Un sistema de visión artificial para estimar la madurez de un tipo de mango se propone en [25]. Un clasificador basado en máquinas de soporte vectorial es empleado para identificar las características de forma más relevantes de entre las 27 extraídas de los canales de color RGB.

En la referencia [26] se describe un sistema de visión artificial para la clasificación y evaluación de la calidad de manzanas, extrayendo los defectos externos y las características de tamaño y de color. Se entrena una red neuronal con los parámetros de calidad de la manzana, los cuales se obtienen de forma experimental.

En [8] se presenta un sistema de visión artificial para seleccionar tomates en base a su madurez en invernaderos. La componente V del espacio de color YUV es empleado para segmentar los tomates del fondo: tallos verdes, follaje y tomates inmaduros. Se desarrolla un extractor de bordes para obtener los bordes curvos que se encuentren dentro de un rango radial, tomando como referencia los modelos de tomates maduros.

Zhang et al. [22] emplean un sistema de visión artificial para reconocer frutas, utilizando características de forma, textura y de color; para la clasificación se entrena una red neuronal artificial combinando el algoritmo back-propagation y algoritmos genéticos. El color se extrae al discretizar cada canal de color en 4 niveles de intensidad, luego se obtiene un histograma donde las frecuencias de los $4 \times 4 \times 4 = 64$ colores

posibles son registradas. Como se menciona en la sección anterior, la propuesta es novedosa y pareciera que la intensidad no afecta a la representación del color. Pero debido a que los colores son representados y procesados en el espacio RGB, es posible que la cromaticidad sea influenciada por la intensidad; de aquí que implementamos esta caracterización del color. Comparamos el desempeño obtenido empleando nuestra propuesta y el presentado por Zhang et al. [22].

En la sección III presentamos nuestra propuesta, la cual es la contribución de este artículo, en cuanto a la selección y extracción de color. También se presentan los métodos de extracción de características de forma y textura.

III. EXTRACCIÓN DE CARACTERÍSTICAS

En esta sección presentamos como se extraen las características de color, forma y textura de las frutas. En la Fig. 2 se muestra el diagrama de flujo de los pasos que se proponen para caracterizar y reconocer frutas.

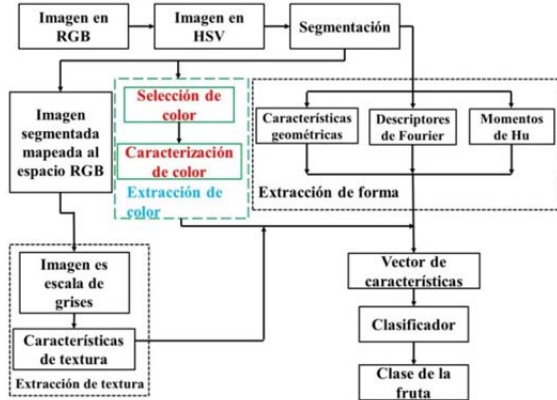


Figura 2. Diagrama de flujo del enfoque propuesto.

Primero, la imagen de la fruta es capturada en el espacio RGB, luego la imagen es mapeada al espacio HSV. La fruta es segmentada del fondo empleando información de la saturación de los colores del fondo. Es importante remarcar que el fondo de las imágenes adquiridas debe ser blanco. Después de la segmentación, se extraen las características de color y de forma. Por separado, la imagen RGB es transformada en escala de grises, luego se obtienen las características de textura. Las características de color, forma y textura son concatenadas para formar el vector de características que representa o modela a la fruta. Este vector es procesado por un clasificador para finalmente reconocer a la fruta.

A. Selección y Extracción de Color

La representación del color en el espacio RGB se basa en el sistema coordenado Cartesiano donde los colores son puntos definidos por los vectores que se extienden desde el origen, donde el negro se encuentra en el origen y el blanco en la esquina opuesta al origen, ver Fig. 3.

El color de un pixel p se representa como una combinación lineal de los vectores base rojo, verde y azul, escrito como:

$$\phi_p = r_p \hat{i} + g_p \hat{j} + b_p \hat{k} \quad (1)$$

Donde r_p , g_p y b_p son los componentes de rojo, verde y azul, respectivamente. La orientación define la cromaticidad mientras que la magnitud representa la intensidad [20].




Figura 3. Espacio de color RGB.

Como se ha mencionado anteriormente, en el espacio RGB, a pesar de que la cromaticidad de un color no cambia, si su intensidad es modificada entonces este puede representar un color diferente. De aquí que empleamos el espacio de color HSV, porque en este espacio la cromaticidad esta desacoplada de la intensidad [20]. El espacio HSV tiene forma de cono, ver Fig. 4, donde los rangos de valores reales del tono, saturación e intensidad son $[0, 2\pi]$, $[0, 1]$ y $[0, 255]$, respectivamente.




Figura 4. Espacio de color HSV.

El color de un pixel p en el espacio HSV se escribe como:

$$\varphi_p = [h_p, s_p, v_p] \quad (2)$$

Donde h_p , s_p y v_p son el tono o cromaticidad, saturación e intensidad, respectivamente. Nótese que el color blanco se encuentra ubicado en la base del cono y en el eje del mismo, por lo que se puede decir que el color blanco es un color con baja saturación. El color negro se encuentra ubicado en la punta del cono, por lo que se puede considerar como un color con baja intensidad.

Assumiendo que en la imagen solo hay una fruta y el fondo es de color blanco, la selección y extracción del color consiste de los siguientes pasos:

1. Sea $\{\phi_1, \dots, \phi_m\} \subset \mathbb{R}^3$ el conjunto de vectores de color de los pixeles de una imagen en el espacio RGB. Los vectores de color se mapean al espacio HSV con lo que se obtiene el conjunto vectores $\{\varphi_1, \dots, \varphi_m\} \subset \mathbb{R}^3$. La segmentación se realiza al comparar la saturación de los colores; si la saturación es baja entonces es un color blanco y por lo tanto esos son los pixeles que son parte del fondo de la imagen. De aquí que si la componente de saturación es menor a un determinado umbral, entonces el valor del pixel correspondiente, en el espacio RGB, es puesto a cero. En otras palabras:

$$\phi_p^* = \begin{cases} \phi_p, & s_p \geq \delta \\ \vec{0}, & s_p < \delta \end{cases} \quad (3)$$

Donde δ es el valor del umbral y $\vec{0} = [0,0,0]$.

2. Se construye el conjunto S como sigue:

$$S = \{\phi_p^* | \phi_p^* \neq \vec{0}\} \quad (4)$$

3. Los vectores del conjunto S son mapeados al espacio HSV, los vectores obtenidos se colocan en el conjunto H . Esto es, sea $T: \mathbb{R}^3 \rightarrow \mathbb{R}^3$ la función que mapea vectores del espacio RGB al espacio HSV:

$$H = \{\phi_p^* = [h_p, s_p, v_p] | T(\phi_p^*) = \phi_p^*, \forall \phi_p^* \in S\} \quad (5)$$

4. Se construye el conjunto $\Psi \subset \mathbb{R}^2$, empleando la componente de tono de los vectores de H :

$$\Psi = \{\psi_p = [\cos h_p, \sin h_p] | \forall \phi_p^* \in H\} \quad (6)$$

5. Se promedian los vectores del conjunto Ψ con:

$$\mu_\psi = \frac{1}{|\Psi|} \sum_{\psi_p \in \Psi} \psi_p \quad (7)$$

6. La matriz de covarianza se calcula:

$$\Omega = \frac{1}{|\Psi|} \Phi \Phi^T \quad (8)$$

Donde Φ es una matriz que se obtiene al colocar en sus columnas el resultado de las diferencias $\psi_p - \mu_\psi$, para todo $\psi_p \in \Psi$. Por lo tanto, el total de columnas de la matriz Φ es el numero de elementos del conjunto Ψ ; en otras palabras, $\Phi \in \mathbb{R}^{2 \times |\Psi|}$.

7. Se obtiene la varianza con la norma de la matriz de covarianza, es decir, $\sigma_\psi^2 = \|\Omega\|$. Esta se calcula con [27]:

$$\|\Omega\| = \sqrt{\lambda(\Omega^T \Omega)} \quad (9)$$

Donde λ es el eigenvalor más grande de la matriz $\Omega^T \Omega$.

8. Los colores discriminativos se seleccionan y sus índices se colocan en el conjunto P_p de esta forma:

$$P_p = \{p | \|\psi_p - \mu_\psi\|^2 < \sigma_\psi^2, \forall \psi_p \in \Psi\} \quad (10)$$

9. Se construye el conjunto $P_\phi = \{\phi_p^* | p \in P_p\}$. Nótese que sus elementos son vectores en el espacio RGB.

10. El color es caracterizado al sumar todos los vectores de color del conjunto P_ϕ :

$$R = \sum_{\phi_p^* \in P_\phi} \phi_p^* \quad (11)$$

11. La magnitud del vector R es muy grande; sin embargo, lo que nos interesa es su orientación porque esto representa la cromaticidad del color característico de la fruta. Por lo tanto, el vector es normalizado con:

$$u_R = \frac{R}{\|R\|} = [r_u, g_u, b_u] \quad (12)$$

Obsérvese que los cosenos directores de este vector son $\cos \alpha_R = r_u / \|u_R\|$, $\cos \beta_R = g_u / \|u_R\|$ y $\cos \theta_R = b_u / \|u_R\|$. Pero $\|u_R\| = 1$, de aquí que, las componentes del vector u_R son los cosenos de los ángulos entre el vector y los vectores base. Por lo tanto, la orientación de R esta implícita en u_R , de esta manera el color de la fruta es caracterizado por u_R .

B. Características de Forma

La forma se modela calculando los descriptores de Fourier, los momentos de Hu y características geométricas básicas. Todas estas características se obtienen al procesar los elementos de $O = \{(x_0, y_0), \dots, (x_{n-1}, y_{n-1})\}$, los cuales son las coordenadas de los píxeles del área segmentada de la imagen. A continuación se presentan los métodos para calcular estas características.

1) Descriptores de Fourier

Los descriptores de Fourier consideran al conjunto de puntos que conforman el contorno de un objeto como una secuencia de números complejos, con los cuales se construye una función periódica unidimensional f que modela el contorno del objeto; los coeficientes de la transformada de Fourier de la función f caracterizan el contorno de un objeto en el dominio de la frecuencia [17].

Sea $C \subset O$ el conjunto de las coordenadas de los píxeles del contorno del área segmentada. Las coordenadas en $C = \{(x_0, y_0), \dots, (x_{M-1}, y_{M-1})\}$ están indexadas de acuerdo a la secuencia en la que se encuentran ubicadas en el contorno en una dirección específica y que comienza en un punto arbitrario. Sea $f: C \rightarrow \mathbb{C}$ la función que transforma una coordenada en un número complejo como sigue:

$$f((x_k, y_k)) = x_k + iy_k \quad (13)$$

Donde $i = \sqrt{-1}$ y \mathbb{C} es el conjunto de números complejos. La transformada de Fourier de la función f se obtiene con:

$$F(u) = \frac{1}{M} \sum_{k=0}^{M-1} f((x_k, y_k)) \exp\left(\frac{-i2\pi uk}{M}\right) \quad (14)$$

A los coeficientes complejos $F(u)$ se les conoce como descriptores de Fourier del contorno. En este trabajo se obtienen 15 coeficientes, esto es, $F(u)$ es calculada para $u = 0, 1, \dots, 14$.

2) Momentos de Hu

Los momentos de Hu son un conjunto de siete descriptores que permiten reconocer un objeto, considerando la forma como una distribución de puntos 2D [18]. Se basa en los momentos centrales normalizados de la distribución de coordenadas, los cuales expresan parámetros característicos respecto al punto centroide. Siendo O el conjunto definido previamente, los momentos centrales de orden pq se definen como:

$$\mu_{pq}(O) = \sum_{(x,y) \in O} (x - \bar{x})^p (y - \bar{y})^q \quad (15)$$

Donde \bar{x} y \bar{y} son los valores promedio de las coordenadas x y y del conjunto O . Los momentos centralizados normalizados η_{pq} se obtienen con:

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^{c+1}} \quad (16)$$

Siendo $c = (p + q)/2$ y $p + q \geq 2$. Por motivos de espacio, no se enlistan las ecuaciones para calcular los siete momentos, pero estas se pueden encontrar en [18].

3) Características Geométricas Básicas

En este trabajo se extraen las siguientes características geométricas. La excentricidad que es la relación entre las longitudes del eje mayor y menor del objeto. La solidez que es la medida en la que una forma es convexa o cóncava.

Compactación:

$$Cp(O) = \frac{n}{P(O)} \quad (17)$$

Redondez:

$$R(O) = \frac{4\pi n}{P^2(O)} \quad (18)$$

Donde $P(O)$ es el perímetro del objeto O , n es la cantidad de píxeles del área segmentada.

C. Características de Textura

La textura no es la primera característica que los humanos observan para reconocer frutas, pero puede ser un dato discriminante entre frutas con formas y colores parecidos. Por ejemplo: naranjas y melones, o mangos y papas.

Las matrices de co-ocurrencia de niveles de gris (MCNG) es uno de los métodos más empleados para caracterizar la textura, el cual fue presentado por Haralick et al. [19].

El MCNG se basa en la distancia entre píxeles, el ángulo y número de niveles de gris. Un elemento $P(i, j, d, \theta)$ de la MCNG representa la frecuencia relativa, donde i es el nivel de gris del pixel ubicado en (x, y) , y j es el nivel de gris del pixel vecino a una distancia y orientación d y θ , respectivamente. El cálculo de las MCNG se basa en la distancia entre píxeles, el ángulo de los píxeles (0° , 45° , 90° y 135°) y el número de niveles de gris. Sea $I(x, y)$ una imagen de tamaño $r \times c$ con n_g niveles de gris, las MCNG, que dependen del ángulo y la distancia, se obtienen con:

$$P(i, j, d, \theta) = \#\{(x_1, y_1), (x_2, y_2) \in r \times c \mid I(x_1, y_1) = i, I(x_2, y_2) = j\} \quad (19)$$

Donde $\#$ denota la cantidad de elementos en el conjunto. $P(i, j, d, \theta)$ representa la información contenida entre dos píxeles $\{(x_1, y_1), (x_2, y_2)\}$ separados por una distancia d y orientados a un ángulo θ .

Se extraen dieciocho características de las MCNG, como se propone en [19]. Las características de textura que se extraen son: energía, contraste, correlación, varianza, homogeneidad, suma promedio, suma de varianza, suma de entropía, entropía, diferencia de varianza, diferencia de entropía, medida de correlación 1 y 2, autocorrelación, prominencia de cumulo, forma de cumulo, disimilitud y máxima probabilidad. Por motivos de espacio, no se anotan las ecuaciones para calcular las características, pero estas se pueden encontrar en [19].

Los valores de las características extraídos de las cuatro orientaciones son promediados, como se sugiere en [19]. Las características de color, forma y de textura son concatenadas para formar un vector que caracteriza a la fruta, este vector es procesado por un clasificador para poder reconocer la fruta capturada en una imagen determinada.

IV. EXPERIMENTOS

En este trabajo seleccionamos 20 clases de frutas comunes en México, ver Fig. 5: cebolla morada, chile verde, lechuga, limón, maíz, mango, manzana roja, melón, naranja, papa, pepino, pera verde, piña, plátano, sandia, tomate, zanahoria, fresa, manzana verde y lechuga romana; etiquetadas como clases 1, 2, ..., 20, respectivamente.

Para apreciar fácilmente la influencia de la caracterización del color seleccionamos frutas con apariencia similar, por ejemplo, cebolla morada y tomate, papa y mango. Empleamos 1720 imágenes, 86 por clase. La mitad de las imágenes se emplea para el entrenamiento y la otra mitad es empleada para realizar pruebas.

Las imágenes deben adquirirse como se menciona en la sección III, esto es, el fondo de las imágenes debe ser blanco; pero también en la escena solo puede aparecer una sola fruta. En [22] no se menciona cuáles son las condiciones en que las imágenes de las frutas son capturadas para sus experimentos.




Figura 5. Imágenes de las clases de frutas empleadas en este trabajo.

En nuestro trabajo, el tamaño de las imágenes varían de 160×159 hasta 1000×965 píxeles; las imágenes son redimensionadas a un tamaño de 480×640 píxeles cuando se extraen las características de textura porque las MCNG no son invariantes a la escala.

La dimensión de los vectores de características empleando nuestra propuesta y la de [22] es 47 y 108, respectivamente. Pero el costo computacional puede ser alto; de aquí que empleamos Análisis de Componentes Principales (ACP) para reducir la dimensión de los vectores.

A. Clasificador Bayesiano

Para el reconocimiento de frutas implementamos un clasificador Bayesiano; este clasificador estadístico se basa en el teorema de Bayes donde se asume que el vector de características es una distribución Gaussiana multivariable.

Sea $C = \{c_1, \dots, c_k\}$ el conjunto de k clases de frutas, la probabilidad de que una fruta \mathbf{x} sea de clase c_i se denota por $p(c_i|\mathbf{x})$. Del teorema de Bayes:

$$p(c_i|\mathbf{x}) = \frac{p(\mathbf{x}|c_i)p(c_i)}{p(\mathbf{x})} \quad (20)$$

Para la clasificación Bayesiana se escoge la clase c_i para la cual $p(\mathbf{x}|c_i)p(c_i)$ es el mayor. De esta forma a la fruta

observada \mathbf{x} se le asigna la clase c_i . Asumimos que la distribución de probabilidad del vector de características de la fruta observada \mathbf{x} , sea de clase c_j , es Gaussiana con media μ_j y con matriz de covarianza Ω_j :

$$p(\mathbf{x}|c_j) = \frac{1}{\Delta} \exp \left[-\frac{1}{2} (\mathbf{x} - \mu_j)^T \Omega_j^{-1} (\mathbf{x} - \mu_j) \right] \quad (21)$$

Donde $\Delta = (2\pi)^{m/2} (\det \Omega_j)^{1/2}$ y m es la dimensión de los vectores de características.

B. Clasificación sin Reducción de Dimensionalidad

La Tabla I muestra los porcentajes de reconocimiento empleando nuestra propuesta y el presentado en [22].

El porcentaje más alto se obtiene con nuestra propuesta, con excepción del reconocimiento de la clase lechuga; es importante saber entre que clases de frutas se dieron los errores de clasificación, con el fin de analizar que caracterización del color funciona mejor.

De aquí que, mostramos las matrices de confusión obtenidas con cada método de extracción de color implementados en este trabajo. En la Tabla II se muestra la matriz de confusión obtenida con la propuesta de [22]. Todas las imágenes de maíz, zanahoria y plátano son clasificadas correctamente; pero también, casi todas las imágenes de fresa, manzana roja, melón y piña son reconocidas exitosamente. Las peor clasificadas son chile verde y sandia.

La Tabla III muestra la matriz de confusión obtenida empleando la extracción de color propuesta por los autores. Al igual que con el método de [22], con nuestro enfoque todas las imágenes de maíz, plátano y zanahoria son clasificadas correctamente, pero también todas las imágenes de limón son clasificadas exitosamente. El reconocimiento de otras clases mejoró; el reconocimiento de las clases de naranja y sandia es el más notable.

TABLA I

TASAS DE RECONOCIMIENTOS OBTENIDOS EMPLEANDO LA PROPUESTA DE LA REFERENCIA [22] Y EL NUESTRO PARA LA CARACTERIZACIÓN DEL COLOR

Numero Clase	Clase de Fruta	Tasa de reconocimiento	
		Propuesta de [22]	Propuesta de autores
1	Cebolla morada	90.70	93.03
2	Chile verde	72.10	81.40
3	Lechuga	88.38	83.73
4	Limón	90.70	100
5	Maíz	100	100
6	Mango	88.38	95.35
7	Manzana roja	93.03	97.68
8	Melon	93.03	95.35
9	Naranja	79.07	95.35
10	Papa	88.38	95.35
11	Pepino	90.70	93.03
12	Pera verde	88.38	95.35
13	Piña	93.03	97.68
14	Plátano	100	100
15	Sandia	76.75	90.70
16	Tomate	90.70	95.35
17	Zanahoria	100	100
18	Fresa	95.35	97.68
19	Manzana verde	88.38	95.35
20	Lechuga romana	90.70	90.70
Promedio		89.89	94.65

TABLA II

MATRIZ DE CONFUSIÓN OBTENIDA CON LA PROPUESTA DE [22]

Clase salida	Clase objetivo									
	1	2	3	4	5	6	7	8	9	10
1	39	0	0	0	0	0	0	0	0	0
2	0	31	0	0	0	0	0	0	0	0
3	0	0	38	1	0	0	0	0	0	0
4	0	0	0	39	0	0	0	0	0	0
5	0	0	0	0	43	1	0	0	0	0
6	0	0	2	1	0	38	0	1	9	4
7	3	0	0	0	0	0	40	0	0	0
8	0	0	0	0	0	0	0	40	0	0
9	0	0	0	0	0	0	0	0	34	0
10	0	0	0	0	0	4	0	2	0	38
11	0	9	0	0	0	0	0	0	0	0
12	0	0	0	2	0	0	0	0	0	0
13	0	0	1	0	0	0	0	0	0	1
14	0	0	0	0	0	0	0	0	0	0
15	0	0	0	0	0	0	0	0	0	0
16	1	0	0	0	0	0	2	0	0	0
17	0	3	0	0	0	0	0	0	0	0
18	0	0	0	0	0	0	1	0	0	0
19	0	0	0	0	0	0	0	0	0	0
20	0	0	2	0	0	0	0	0	0	0

Clase salida	Clase objetivo									
	11	12	13	14	15	16	17	18	19	20
1	0	0	0	0	0	0	0	0	0	0
2	3	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	3	3
4	0	3	0	0	9	0	0	0	0	0
5	0	0	0	0	0	0	0	0	0	0
6	0	0	3	0	0	0	0	0	0	0
7	0	0	0	0	0	4	0	2	0	0
8	0	0	0	0	0	0	0	0	0	0
9	0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0	0
11	39	0	0	0	0	0	0	0	0	0
12	0	38	0	0	0	0	0	0	0	0
13	0	0	40	0	0	0	0	0	0	0
14	0	0	0	43	0	0	0	0	0	1
15	1	2	0	0	33	0	0	0	2	0
16	0	0	0	0	0	39	0	0	0	0
17	0	0	0	0	0	0	43	0	0	0
18	0	0	0	0	0	0	0	41	0	0
19	0	0	0	0	0	0	0	0	38	0
20	0	0	0	0	1	0	0	0	0	39

Dada la alta dimensión de los vectores, el costo computacional para procesar estos vectores puede ser muy alto; de aquí que se aplica ACP para reducir la dimensión.

C. Clasificación con Reducción de Dimensionalidad

El número de eigenvectores se determina considerando que la suma de los respectivos eigenvalores, ordenados descendientemente, sea el 95% de la varianza acumulada. De aquí que la dimensión de los vectores empleando nuestra propuesta y la de [22] se reduce a 18 y 25, respectivamente. La Tabla IV muestra los resultados obtenidos empleando nuestro enfoque y el de [22] al reducir la dimensionalidad.

El reconocimiento mejoro ligeramente con respecto a los resultados obtenidos sin aplicar ACP; nuestra propuesta tuvo el mejor desempeño. El reconocimiento de algunas frutas mejoro, como la fresa y pepino; pero en otras disminuyo, por ejemplo, maíz y plátano. La matriz de confusión obtenida

empleando la propuesta de extracción del color de [22] se muestra en la Tabla V.

Las frutas mejor clasificadas son limón y piña, esto es, todas las imágenes son reconocidas exitosamente. El reconocimiento de plátano y zanahoria es más bajo al que se obtiene sin utilizar ACP. Las frutas peor clasificadas son cebolla morada y sandia. En la Tabla VI se muestra la matriz de confusión obtenida utilizando nuestra propuesta y aplicando ACP. Las frutas mejor clasificadas son naranja y zanahoria, mientras que las peor clasificadas son lechuga y lechuga romana. Aunque el reconocimiento de las frutas mejora al aplicar ACP, hay clases de frutas cuyo reconocimiento disminuyó.

TABLA III

MATRIZ DE CONFUSIÓN OBTENIDA EMPLEANDO NUESTRA PROPUESTA

Clase salida	Clase objetivo									
	1	2	3	4	5	6	7	8	9	10
1	40	0	0	0	0	0	0	0	0	0
2	0	35	0	0	0	0	0	0	0	0
3	0	0	36	0	0	0	0	0	0	0
4	0	0	3	43	0	0	0	0	0	0
5	0	0	0	0	43	0	0	0	0	0
6	0	0	0	0	0	41	0	0	1	2
7	3	0	0	0	0	0	42	0	1	0
8	0	0	0	0	0	0	0	41	0	0
9	0	0	0	0	0	0	0	2	41	0
10	0	0	0	0	0	2	0	0	0	41
11	0	8	0	0	0	0	0	0	0	0
12	0	0	0	0	0	0	0	0	0	0
13	0	0	0	0	0	0	0	0	0	0
14	0	0	0	0	0	0	0	0	0	0
15	0	0	4	0	0	0	0	0	0	0
16	0	0	0	0	0	0	1	0	0	0
17	0	0	0	0	0	0	0	0	0	0
18	0	0	0	0	0	0	0	0	0	0
19	0	0	0	0	0	0	0	0	0	0
20	0	0	0	0	0	0	0	0	0	0
Clase salida	Clase objetivo									
	11	12	13	14	15	16	17	18	19	20
1	0	0	0	0	0	0	0	0	0	0
2	3	1	0	0	0	0	0	0	2	0
3	0	1	0	0	1	0	0	0	0	0
4	0	0	0	0	3	0	0	0	0	1
5	0	0	0	0	0	0	0	0	0	0
6	0	0	0	0	0	0	0	0	0	0
7	0	0	0	0	0	2	0	1	0	0
8	0	0	0	0	0	0	0	0	0	0
9	0	0	0	0	0	0	0	0	0	0
10	0	0	0	0	0	0	0	0	0	0
11	40	0	0	0	0	0	0	0	0	0
12	0	41	0	0	0	0	0	0	0	0
13	0	0	42	0	0	0	0	0	0	0
14	0	0	0	43	0	0	0	0	0	0
15	0	0	1	0	39	0	0	0	0	3
16	0	0	0	0	0	41	0	0	0	0
17	0	0	0	0	0	0	43	0	0	0
18	0	0	0	0	0	0	0	42	0	0
19	0	0	0	0	0	0	0	0	41	0
20	0	0	0	0	0	0	0	0	0	39

V. DISCUSIÓN

De acuerdo a la Tabla I, el reconocimiento promedio más alto se obtiene empleando nuestra propuesta de extracción de color, para todas las clases de frutas. Excepto por la clase de lechuga romana, donde el porcentaje de reconocimiento más alto se obtiene con la propuesta de Zhang et al. [22].

Al revisar las matrices de confusión de la Tabla II las frutas mejor clasificadas, empleando el método de Zhang et al. [22], son maíz, plátano y zanahoria, donde el porcentaje de reconocimiento es del 100%. Por otra parte, las frutas peor clasificadas son sandía, chile verde y naranja. Nueve imágenes de sandía son clasificadas como limón y una como lechuga romana. El limón es clasificado en nueve imágenes como pepino y tres imágenes de limón son reconocidas como zanahoria. Nueve imágenes de naranja son clasificadas como mango. La mayoría de los errores de clasificación ocurren entre frutas cuyas apariencias son similares. Esto es, cebolla morada es clasificada como manzana roja y tomate; lechuga es clasificada como mango, piña y lechuga romana; limón es clasificado como lechuga, mango y pera verde; mango es clasificado como maíz y papa; manzana roja es clasificada como tomate y fresa; melón es clasificado como mango y papa; papa es clasificado como mango y piña; pepino es clasificado como lechuga y sandia; lechuga romana es clasificada como lechuga y plátano. Dado que los colores son discretizados, varios de estos son agrupados en la misma clase de cromaticidad, es por esto que la diferencia entre la cromaticidad de los colores no es precisa, lo que lleva a errores de clasificación. Al emplear nuestra propuesta de caracterización de color, el reconocimiento de las frutas mejora, excepto para la clase de lechuga. Las frutas mejor clasificadas son limón, maíz, plátano y zanahoria; mientras que las peor son chile verde y lechuga, ver Tabla I.

TABLA IV

TASAS DE RECONOCIMIENTOS OBTENIDOS EMPLEANDO LA PROPUESTA DE [22] Y EL NUESTRO PARA LA CARACTERIZACIÓN DEL COLOR, APLICANDO ACP

Numero Clase	Clase de Fruta	Tasa de reconocimiento	
		Propuesta de [22]	Propuesta de autores
1	Cebolla morada	81.40	97.68
2	Chile verde	83.73	93.03
3	Lechuga	88.38	90.70
4	Limón	100	97.68
5	Maíz	93.04	95.35
6	Mango	95.35	93.03
7	Manzana roja	95.35	95.35
8	Melón	93.03	93.03
9	Naranja	93.03	100
10	Papa	90.70	95.35
11	Pepino	93.03	97.68
12	Pera verde	95.35	97.68
13	Piña	100	97.68
14	Plátano	97.68	95.35
15	Sandia	81.40	95.35
16	Tomate	95.35	95.35
17	Zanahoria	95.35	100
18	Fresa	90.70	95.35
19	Manzana verde	83.73	95.35
20	Lechuga romana	83.73	90.70
Promedio		91.52	95.59

Los errores de clasificación se dan como se explica a continuación, ver Tabla III. Cebolla morada es clasificada como manzana roja; mango es clasificado como papa; manzana roja es reconocida como tomate; melón es clasificado como naranja; naranja es clasificado como mango y manzana roja; papa es reconocida como mango; pepino es clasificado como chile verde; pera verde es clasificado como chile verde y lechuga; piña es reconocido como sandia; sandia es clasificada como lechuga y limón; tomate es reconocido como manzana roja; fresa es clasificada como manzana roja; manzana verde es reconocida como chile verde; lechuga romana es clasificada como limón y sandia.

Al aplicar ACP la tasa de reconocimiento aumenta ligeramente en ambas propuestas; aunque el reconocimiento de unas clases de frutas mejora, en otras disminuye.

Utilizando el método de [22], las tasas de reconocimiento de las siguientes frutas mejoraron: chile verde, limón, mango,

TABLE V

MATRIZ DE CONFUSIÓN OBTENIDA EMPLEANDO LA PROPUESTA
DE LA REFERENCIA [22], APLICANDO ACP

[illegible]

manzana roja, naranja, papa, pepino, pera verde, piña, sandía y tomate. Por otra parte, el reconocimiento disminuyó con las siguientes frutas: maíz, plátano, zanahoria, fresa, manzana verde y lechuga romana. De la matriz de confusión de la Tabla V, las frutas cuya tasa de reconocimiento se redujo son clasificadas como sigue: maíz es reconocido como papa y zanahoria; plátano es clasificado como maíz; zanahoria es reconocido como pepino; fresa es reconocido como manzana roja; manzana verde es clasificada como lechuga y sandía; lechuga romana es reconocida como pepino y sandía.

Con nuestro método las tasas de reconocimiento de cebolla morada, chile verde, lechuga, melón, naranja, pepino, pera verde y sandía mejoran. El reconocimiento de las siguientes clases de frutas decayó: limón, maíz, mango, manzana roja, plátano y fresa. Considerando la matriz de confusión de la Tabla VI, las frutas cuya tasa de reconocimiento disminuye son clasificadas así: limón es clasificado como sandía; maíz es

TABLE VI

MATRIZ DE CONFUSIÓN OBTENIDA EMPLEANDO NUESTRA
PROPUESTA, APLICANDO ACP

[illegible]

reconocido como mango; mango es clasificado como papa; manzana roja es reconocida como cebolla morada y tomate; melón es clasificado como naranja y papa; plátano es reconocido como chile verde y zanahoria; fresa es clasificada como manzana roja y tomate.

El costo computacional es menor con nuestra propuesta porque la dimensión de los vectores de características es menor que la dimensión de los vectores de características que se obtienen al utilizar la propuesta de [22], aun reduciendo la dimensionalidad con ACP. Debido a que se considera implementar nuestro método en supermercados, el reconocimiento de las frutas debe ser rápido.

VI. CONCLUSIONES Y TRABAJO FUTURO

Se ha presentado una propuesta de caracterización de color para el reconocimiento de frutas empleando visión artificial. Los mejores resultados se obtienen empleando nuestra propuesta de extracción del color por su cromaticidad. El costo computacional es menor con nuestra propuesta que la de [22]; esto es porque modelamos el color con vectores de dimensión 3 mientras que en [22] se emplean vectores de dimensión 64. Dado que nuestro método se planea implementarse en supermercados es necesario atender lo siguiente: (a) Incrementar el número de clases de frutas a reconocer, en los supermercados la cantidad de clases de frutas que venden es grande; (b) Adquirir imágenes de frutas en diferentes ángulos y/o con cierto grado de oclusión con el fin de robustecer el reconocimiento; (c) considerar emplear otros tipos de clasificadores; por ejemplo, redes neuronales o aquellos basados en lógica difusa.

REFERENCIAS

- [1] F. Rodríguez-Pulido, B. Gordillo, L. González-Miret and F. Heredia, "Analysis of Food Appearance Properties by Computer Vision Applying Ellipsoids to Color Data", *Computers and Electronics in Agriculture*, vol. 99, pp. 108-115, 2013.
- [2] C.J. Du and D.W. Sun, "Learning Techniques Used in Computer Vision for Food Quality Evaluation: A Review", *Journal of Food Engineering*, vol. 72, no. 1, pp. 39-55, 2006.
- [3] A. Manickavasagan, N. Al-Mezeini and H. Al-Shekaili, "RGB Color Imaging Technique for Grading of Dates", *Scientia Horticulturae*, vol. 175, pp. 87-94, 2014.
- [4] B. Zhang, W. Huang, J. Li, C. Zhao, S. Fan, J. Wu and C. Liu, "Principles, Developments and Applications of Computer Vision for External Quality Inspection of Fruits and Vegetables: A Review", *Food Research International*, vol. 62, pp. 326-343, 2014.
- [5] P. Cano Marchal, D. Martinez Gila, J. Gamez Garcia and J. Gomez Ortega, "Expert System Based on Computer Vision to Estimate the Content of Impurities in Olive Samples", *Journal of Food Engineering*, vol. 119, no. 2, pp. 220-228, 2013.
- [6] A. Nureize, J. Watada and S. Wang, "Fuzzy Random Regression Based Multi-Attribute Evaluation and Its Application to Oil Palm Fruit", *Annals of Operations Research*, vol. 219, no. 1, pp. 299-315, 2014.
- [7] G. Gatica, S. Best, J. Ceroni and G. Lefranc, "Olive Fruits Recognition Using Neural Networks", *Procedia Computer Science*, vol. 17, pp. 412-419, 2013.
- [8] X. Chen and S. Yang, "A Practical Solution for Ripe Tomato Recognition and Localisation", *Journal of Real-Time Image Processing*, vol. 8, no. 1, pp. 35-51, 2013.
- [9] J.-J. Wang, D.-A. Zhao, W. Ji, J.-J. Tu and Y. Zhang, "Application of Support Vector Machine to Apple Recognition Using in Apple Harvesting Robot", *International Conference on Information and Automation*, pp. 1110-1115, 2009.
- [10] E. van Henten, J. Hemming, B. van Tuijl, J. Kornet, J. Meuleman, J. Bontsema and E.A. van Os, "An Autonomous Robot for Harvesting

Cucumbers in Greenhouses", *Autonomous Robots*, vol. 13, no. 3, pp. 241-258, 2002.

- [11] C. Costa, F. Antonucci, F. Pallottino, J. Aguzzi, D.W. Sun and P. Menesatti, "Shape Analysis of Agricultural Products: A Review of Recent Research Advances and Potential Application to Computer Vision", *Food and Bioprocess Technology*, vol. 4, no. 5, pp. 673-692, 2011.
- [12] U. Ben-Hanan, K. Peleg and P.-O. Gutman, "Classification of Fruits by a Boltzmann Perceptron Neural Network", *Automatica*, vol. 28, no. 5, pp. 961-968, 1992.
- [13] A. Suyantohadi, G. Mulyati, W. Supartono, H. Purwadaria, K. Seminar, X. Suroso, R.J. Widodo and H.A. Tjokronegoro, "Identification of the Maturity Level of Mango Arumanis Based on Non-Destructive Method Using Artificial Neural Network". *Workshop on Intelligent Control for Agricultural Applications*, pp. 313-317, 2001.
- [14] C. Pellerin, "Machine Vision in Experimental Poultry Inspection", *Sensor Review*, vol. 15, no. 4, 1995.
- [15] T. Pholpho, S. Pathaveerat and P. Sirisomboon, "Classification of Logan Fruit Bruising Using Visible Spectroscopy", *Journal of Food Engineering*, vol. 104, no. 1, pp. 169-172, 2011.
- [16] Z. Haddi, S. Mabrouk, M. Bougrini, K. Tahrir, K. Sghaier, H. Barhoumi, N. El Bari, A. Maaref, N. Jaffrezic-Renault and B. Bouchikhi, "E-Nose and E-Tongue Combination for Improved Recognition of Fruit Juice Samples", *Food Chemistry*, vol. 150, no. 1, pp. 246-253, 2014.
- [17] C. Zahn and R. Roskies, "Fourier Descriptors for Plane Close Curves", *IEEE Transactions on Computers*, vol. C-21, no. 3, pp. 269-281, 1972.
- [18] M.K. Hu, "Visual Pattern Recognition by Moment Invariants", *IRE Transactions on Information Theory*, vol. 8, no. 2, pp. 179-187, 1962.
- [19] R.M. Haralick, K. Shanmugam and I. Dinstein, "Textural Features for Image Classification", *IEEE Transactions on Systems, Man and Cybernetics*, vol. SMC-3, no. 6, pp. 610-621, 1973.
- [20] R. Gonzalez and R. Woods. *Digital Image Processing*. Ed. Prentice Hall, 2002.
- [21] S. Ito, M. Yoshioka, S. Omatu, K. Kita and K. Kugo, "An Image Segmentation Method Using Histograms and the Human Characteristics of HIS Color Space for a Scene Image, *Artificial Life and Robotics*, vol. 10, no. 1, pp. 6-10, 2006.
- [22] Y. Zhang, S. Wang, G. Ji and P. Phillips, "Fruit Classification Using Computer Vision and Feedforward Neural Network", *Journal of Food Engineering*, vol. 143, pp. 167-177, 2014.
- [23] B. Bostanci, H. Hagrais and J. Dooley, "A Neuro Fuzzy Embedded agent Approach Towards the Development and Intelligent Refrigerator". *IEEE International Conference on Fuzzy Systems*, pp. 1-8, 2013.
- [24] W.C. Seng and S.H. Mirisae, "A New Method for Fruits Recognition System", *International Conference on Electrical Engineering and Informatics*, pp. 130-134, 2009.
- [25] C. Sekhar Nandi, B. Tudu and C. Koley, "A Machine Vision-Based Maturity Prediction System for Sorting of Harvested Mangoes", *IEEE Transactions on Instrumentation and Measurement*, vol. 63, no. 7, pp. 1722-1730, 2014.
- [26] A. Bhatt and D. Pant, "Automatic Apple Grading Model Development Based on Back Propagation Neural Network and Machine Vision, and Its Performance Evaluation", *AI & Society*, vol. 30, no. 1, pp. 45-56, 2015.
- [27] I. Bronshtein, K. Semendyayev, G. Musiol and H. Muehlig, *Handbook of Mathematics*. Springer-Verlag, 2007.



robotics.

Farid García Lamont received a B.Sc. degree in Robotics from ESIME-IPN, México in 2000; in 2004 obtained a M.Sc. in Automatic Control from the Centro de Investigación y de Estudios Avanzados del IPN (CINVESTAV-IPN), México. In 2010 received a PhD degree in Computer Science from CINVESTAV-IPN. His research interests are pattern recognition, applications of artificial intelligence and



Jair Cervantes received the B.Sc. degree in Mechanical Engineering from Orizaba Technologic Institute, Veracruz, Mexico, in 2001, a M.Sc. degree and a PhD from CINVESTAV-IPN, México, in 2005 and 2009 respectively. His research interests include support vector machine, pattern classification, neural networks, fuzzy logic and clustering.



Asdrúbal López Chau received a PhD in Computer Science from the Department of Computer Science at CINVESTAV-IPN Mexico, in 2013, a M.Sc. degree in Computer Engineering from CIC-IPN Mexico in 2000, and a B.Sc. Degree in Electronic Engineering from ESIME-IPN Mexico in 1997. His research interests include machine learning, computational intelligence and data mining.



Matias Alvarado received a PhD in Computer Science and Research Sufficiency in Computer Science, from Department of Language and Informatics Systems at Technical University of Catalonia, Spain, in 1998 and 1993, respectively. Currently, he is research scientist at Department of Computer Science CINVESTAV-IPN. His research interests are game theory, analysis of complex networks and pattern recognition.